

三道追问问题补充思路

郭一帆

目录

1 追问一：RAG 系统回答准确性提升	
1.1 数据工程优化	
1.2 查询理解与人工介入	
1.3 混合检索与重排序	
1.4 约束模型基于检索证据回答	
1.5 使用监督微调提升模型使用证据的能力	
2 追问二：诊断能力跨病种迁移	
2.1 在 Skill 中抽象通用诊断流程	
2.2 在模型提示词中加入正面和负面的少样本示例	
2.3 针对数据量不足扩充病例示例库	
2.4 在 Agent 流程中增加“先诊断、再自检”	
3 追问三：医疗诊断 Agent 量化评估体系	
3.1 建立多级标签体系	
3.2 为不同层级设置量化指标	
3.3 使用语义相似度和评价模型检查生成答案	
3.4 用专家标准集校准自动评价体系	

1 追问一：本地小模型、无多模态及数据不外泄条件下，如何提高 RAG 系统的回答准确性？

我的思路是将问题拆分为数据工程、查询理解、检索和生成四个环节，先保证知识库内容可靠、用户问题足够明确、检索结果准确，再提高模型使用检索证据的能力。

1.1 数据工程优化（面试时已提到）

这一部分主要作用于医疗资料进入知识库之前的数据处理阶段。首先对原始医疗文档进行清洗，去除重复、过期、错误或相互冲突的内容，并保留疾病类型、人体部位、检查项目、文档版本等元数据，方便后续检索时进行筛选。

文本分块不能只按照固定字数切分，而应结合标题、段落、完整句子和语义边界进行切分。重叠区域（overlap）也不应固定为 50 或 100 个字符：如果症状、检查条件和诊断结论跨越分块边界，就适当扩大重叠范围。如果前后内容已经属于不同主题，则不需要强行重叠。核心是保证“症状—指标—条件—结论”等完整医学语义不被拆开。

还可以在文档入库阶段进行命名实体识别和关系抽取，提取疾病、症状、人体部位、检验指标等实体，以及“疾病—症状”“疾病—检验指标”等关系。较轻量的做法是将实体和关系保存为文本块的结构化标签，用于检索过滤和查询扩展。如果需要支持跨文档的关系查询，可以进一步将实体作为节点、关系作为边，构建轻量级医疗知识图谱。知识图谱负责组织实体关系，原始医疗文档仍负责提供完整且可追溯的诊断依据。

1.2 查询理解与人工介入（个人项目有类似实现）

这一部分作用于用户提出问题后、系统正式检索之前。医疗场景中的问题可能过于模糊，例如用户只询问“这个指标高是什么原因”，但没有给出具体指标名称、检测值、参考范围、人体部位或相关

症状。如果直接进入检索，后续召回和回答都会建立在不完整的查询上，容易产生无效召回或错误判断。因此，可以在检索前先判断问题是否包含必要信息。当缺少核心实体、问题存在多种解释，或者不同解释会对应明显不同的检索方向时，系统暂时中断当前流程，并向用户提出有针对性的补充问题。例如：请补充具体指标名称、检测值、参考范围，以及是否存在相关症状。

用户补全信息后，系统再将新增内容与原问题合并，形成更完整、明确的查询，然后进入关键词检索、向量检索和重排序流程。这种人工介入机制（human-in-the-loop, HITL）相当于在检索前增加一道查询质量控制：先保证“问题问清楚”，再从知识库中寻找答案，从而减少无效召回、错误匹配以及模型基于不完整信息作出过度判断的情况。

1.3 混合检索与重排序（个人项目有类似实现）

这一部分作用于用户提出问题之后、模型生成答案之前的检索阶段。向量检索用于召回语义相近但表达方式不同的内容，关键词检索用于精确匹配疾病名称、医学缩写、药物名称和检验指标。将两类结果合并，可以同时兼顾语义召回和医学术语的准确匹配。

初步召回后，再使用本地部署的重排序模型，对候选文本与当前问题的相关性重新评分，重点检查疾病、人体部位、检查指标和诊断条件是否一致，减少“语言相似但医学含义不一致”的结果。评估时可使用前 K 项召回率（Recall@K）等指标，检查正确证据是否进入候选结果，从而判断问题发生在知识库、检索、重排序还是最终生成阶段。

1.4 约束模型基于检索证据回答（个人项目有类似实现）

这一部分作用于生成模型的提示词和 Agent 回答流程。在提示词中明确要求模型只能依据检索到的资料回答，并给出对应依据。若检索内容与问题无关、不同资料之间存在冲突，或者现有信息不足以支持结论，模型应输出“证据不足”或“需要补充检查”，而不是强行给出诊断。该方法不修改模型参数，可以直接降低本地小模型的幻觉，并提高回答的可追溯性。

1.5 使用监督微调提升模型使用证据的能力

如果知识库和检索链路已经优化，但模型仍然不能正确使用证据，可以对本地生成模型进行监督微调（SFT）。训练输入由“用户问题、检索到的医疗资料和回答要求”组成，标准输出包括最终判断、支持证据、证据来源、当前缺失的信息，以及证据不足时的拒答方式。

训练数据既要包含证据充分、可以正确回答的正面样本，也要包含检索内容无关、证据互相冲突、信息不足和模型历史错误案例等负面样本。监督微调的目的不是让模型记住全部医疗知识，而是让模型学会从检索结果中提取有效信息、忽略无关内容，并在证据不足时保持谨慎。

强化学习可以作为后续优化，通过专家对不同答案的偏好，让模型进一步学习正确性、证据一致性和安全性。但专家偏好数据的标注成本较高，因此优先级低于数据工程、混合检索、重排序和监督微调。

2 追问二：已有某一疾病领域的诊断能力，但不能微调模型，是否认同将诊断能力封装成 Skill 的做法？如何迁移到其他病种？

我认为上一个实习生将病历诊断能力封装成 Skill 的做法有可取之处，整体思路是正确的。Skill 可以把病例解析、知识检索、诊断步骤和结果输出封装成相对固定的流程，使 Agent 能够复用已有能力，也便于调试和维护。

但这种做法存在两个局限：一是如果每个病种都单独开发一个 Skill，随着病种增加，开发和维护成本会不断上升，不同病种之间的通用诊断逻辑也难以复用；二是新病种通常存在数据量不足的问题，可能没有足够病例支持单独训练或构建完整的病种流程。因此，我会保留 Skill 的模块化思路，并从以下方面进行补充。

2.1 在 Skill 中抽象通用诊断流程

这一方法主要作用于 Agent 的工作流设计层。不同病种可以共用一套结构化诊断步骤：

1. 提取症状、病史和检查结果；
2. 识别异常指标；
3. 生成候选疾病；
4. 分析各候选疾病的支持证据和反对证据；
5. 进行鉴别诊断；
6. 判断当前证据是否充分；
7. 输出诊断结果，或者指出需要补充的检查。

这样可以将“一个病种对应一个 Skill”调整为“一个通用诊断 Skill 加不同病种的知识 and 案例”。迁移到新病种时，主要补充该病种的知识文档、判断条件和病例示例，不需要修改模型参数，也不需要重新开发完整流程。

2.2 在模型提示词中加入正面和负面的少样本示例

这一方法用于模型每次推理时的上下文学习，不用于修改模型参数。可以在本地建立病例示例库，每个示例包含患者症状、病史、检查指标、最终结论、支持证据、反对证据和判断原因。

- 正面样本包括症状和检查指标较典型的确诊病例，以及症状不典型但关键检查结果能够支持诊断的病例。
- 负面样本包括症状相似但实际属于其他疾病的病例、只有部分症状符合但缺少关键诊断依据的病例、某项指标异常但异常原因不是目标疾病的病例、正常或未患病病例，以及模型历史上容易误判的错误案例。

处理新病例时，系统先根据患者的症状、人体部位和检查指标，从示例库中动态检索少量相似的正面病例和容易混淆的负面病例，再将这些示例与当前病例一起加入模型提示词。这样模型既能参考“什么情况下可以判断为该疾病”，也能对比“什么情况下虽然相似，但不能判断为该疾病”。

2.3 针对数据量不足扩充病例示例库

由于新病种的病例数据有限，数据增强主要用于扩充上下文学习的示例库和离线评估集，而不是更新模型参数。对于病历文本，可以进行医学全称、简称和缩写之间的替换，调整病史和症状的描述顺序，删除不影响诊断的非关键信息，并构造缺少关键检查依据或症状相似但诊断不同的困难负样本（hard negative）。

如果任务包含医学图像，可以进行适度旋转、裁剪和添加符合成像特点的噪声，但不能裁掉病灶或改变医学语义。增强后的案例可以加入少样本示例库，在推理时优先选择与当前病例相关的样本。

当前场景不能微调模型，因此加权损失函数不能直接使用。如果后续条件允许微调，可以提高损失函数对负面样本，尤其是困难负样本的权重，并对误诊、漏诊等高风险错误设置更高的惩罚权重。

2.4 在 Agent 流程中增加“先诊断、再自检”

这一方法作用于模型完成初步诊断后的第二阶段推理。第一阶段由模型输出初步诊断、支持证据、反对证据以及当前缺少的信息。第二阶段再让模型以审核者的角度检查：

- 结论是否有病例中的证据支持；
- 是否忽略了与结论矛盾的信息；
- 是否使用了病例中不存在的信息；
- 是否还有其他需要排除的相似疾病；
- 当前证据是否足以作出确定判断。

根据检查结果，最终输出可以分为“保留原结论”“修改结论”或“证据不足”。模型自检不能替代医疗专家，但可以发现明显的证据矛盾、信息遗漏和过度判断。自检中发现的错误案例还可以继续补充到负面示例库中，形成“诊断—自检—错误案例积累”的迭代过程。

3 追问三：医疗诊断 Agent 如何判断答案质量？在专家时间有限的情况下，如何建立量化评估体系？

我的思路是先建立结构化评估数据集和多级标签，使大部分答案能够自动评价，再使用少量专家标注校准自动评价体系。

3.1 建立多级标签体系

这一部分作用于测试数据集的人工标注阶段。以医学图像诊断任务为例，可以将标准答案拆分为三级标签：

- 第一级判断图片类型，例如 X 光、CT、超声、胃镜或肠镜；
- 第二级判断人体部位或器官，例如胸部、腹部、胃、食管或结肠；
- 第三级判断是否存在疾病或异常，例如正常、异常、患病或未患病。

这种方式不仅能判断最终答案是否正确，还可以定位错误发生在图片类型识别、人体部位识别还是疾病判断阶段。

3.2 为不同层级设置量化指标

这一部分作用于离线测试和模型版本对比阶段。图片类型和人体部位属于多分类任务，可以计算准确率、精确率、召回率和宏平均 F1 值（Macro-F1）。是否患病属于二分类任务，除准确率外，还应重点关注患病召回率、特异度、假阳性率、假阴性率和 F1 值。医疗场景中，假阴性代表漏诊，因此不能只看总体准确率。

除每一级的独立指标外，还可以统计三级标签全部判断正确的端到端准确率。对于模型输出的关键异常、检查指标和诊断依据，可以先转成结构化标签，再计算证据级的精确率、召回率和 F1 值。

3.3 使用语义相似度和评价模型检查生成答案

对于模型生成的解释性文本，可以使用语义相似度判断其与标准答案在含义上是否接近，但语义相似度只能作为辅助指标，因为语言表达相似并不代表医学结论一定正确。

还可以在本地或私有环境中部署能力更强的评价模型（judge model），按照统一标准逐项检查，评价模型需要输出各项判断和对应的错误原因，而不是只给出一个总体分数。

评价维度	检查内容
图片类型	图片类型是否识别正确
人体部位	人体部位或器官是否判断正确
患病情况	是否患病、是否存在异常的判断是否正确
证据来源	诊断依据是否来自输入图片、病历或检索资料
证据一致性	诊断依据是否能够支持最终结论
信息完整性	是否遗漏关键异常、症状或检查指标
事实忠实性	是否使用输入中不存在或与证据冲突的信息
最终结论	模型结论是否与标准答案一致

3.4 用专家标准集校准自动评价体系

这一部分作用于评价模型正式大规模使用之前的校准阶段。可以由医疗专家标注一小批专家标准集（gold set），覆盖不同图片类型、人体部位、正常病例、患病病例、容易混淆的疾病、信息不足的病例和模型历史错误案例。

评价模型先在这批数据上进行评分，再将结果与专家结论进行比较，根据差异调整评价提示词和评分规则。完成校准后，大部分样本可以由自动指标和评价模型完成初步评价，专家主要审核低置信度样本、自动指标与评价模型结果不一致的样本、假阴性或假阳性风险较高的样本、新病种或少样本病种，以及模型历史上频繁出错的病例。

同时可以随机抽取少量普通样本进行复核，防止自动评价体系产生系统性偏差。这样能够在减少专家工作量的同时，建立相对稳定、可量化的评估体系。